Video Game Sales 电子游戏销售分析

数据集：Video Game Sales (https://www.kaggle.com/gregorut/videogamesales)

该数据集包含游戏名称、类型、发行时间、发布者以及在全球各地的销售额数据。

数据量：11列共1.66W数据。

基于这个数据集，可进行以下问题的探索：

- 电子游戏市场分析：受欢迎的游戏、类型、发布平台、发行人等；
- 预测每年电子游戏销售额；
- 可视化应用：如何完整清晰地展示这个销售故事。

In [1]:
```
import os
import time
import pandas as pd   # data processing, csv file I/O
import numpy as np
import matplotlib.pyplot as plt
```

In [2]:
```
# timekeeping
timekeeping = time.time()

# load data
data = pd.read_csv('vgsales.csv')

# description of data set
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 16598 entries, 0 to 16597
Data columns (total 11 columns):
 #   Column        Non-Null Count  Dtype  
---  ------        --------------  -----  
 0   Rank          16598 non-null  int64  
 1   Name          16598 non-null  object 
 2   Platform      16598 non-null  object 
 3   Year          16327 non-null  float64
 4   Genre         16598 non-null  object 
 5   Publisher     16540 non-null  object 
 6   NA_Sales      16598 non-null  float64
 7   EU_Sales      16598 non-null  float64
 8   JP_Sales      16598 non-null  float64
 9   Other_Sales   16598 non-null  float64
 10  Global_Sales  16598 non-null  float64
dtypes: float64(6), int64(1), object(4)
memory usage: 1.4+ MB
```

In [3]:
```
# NaN info
data.isna().sum()
```

Out[3]:
```
Rank              0
Name              0
Platform          0
Year            271
Genre             0
Publisher        58
NA_Sales          0
EU_Sales          0
JP_Sales          0
Other_Sales       0
Global_Sales      0
dtype: int64
```

数据预处理

观察数据描述可得，属性 `Year` 和 `Publisher` 有缺失值，针对这两个属性自身的意义，选择用**最高频率值来填补缺失值**

In [4]:
```
# Get frequency of Year & Publisher arrtibute
mode_Year = data.mode()['Year'][0]
mode_Publisher = data.mode()['Publisher'][0]

# Fill NA/NaN values using the highest frequency value.
new_data = data.fillna({'Year': mode_Year, 'Publisher': mode_Publis
her})
new_data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 16598 entries, 0 to 16597
Data columns (total 11 columns):
 #   Column        Non-Null Count  Dtype  
---  ------        --------------  -----  
 0   Rank          16598 non-null  int64  
 1   Name          16598 non-null  object 
 2   Platform      16598 non-null  object 
 3   Year          16598 non-null  float64
 4   Genre         16598 non-null  object 
 5   Publisher     16598 non-null  object 
 6   NA_Sales      16598 non-null  float64
 7   EU_Sales      16598 non-null  float64
 8   JP_Sales      16598 non-null  float64
 9   Other_Sales   16598 non-null  float64
 10  Global_Sales  16598 non-null  float64
dtypes: float64(6), int64(1), object(4)
memory usage: 1.4+ MB
```

数据集探索

受欢迎的游戏、类型、发布平台、发行人等

- 根据数据集中的 `Rank` 属性（整体销售排名）可以得出全球最受欢迎的游戏、类型、发布平台以及发行人。
- 根据其他销售属性（i.e., `NA_Sales` , `EU_Sales` , `JP_Sales` , `Other_Sales` ）也可以得出相应地区的相关信息。

In [5]:
```
data.head()
```

Out[5]:

	Rank	Name	Platform	Year	Genre	Publisher	NA_Sales	EU_Sales	JP_Sale
0	1	Wii Sports	Wii	2006.0	Sports	Nintendo	41.49	29.02	3.7
1	2	Super Mario Bros.	NES	1985.0	Platform	Nintendo	29.08	3.58	6.8
2	3	Mario Kart Wii	Wii	2008.0	Racing	Nintendo	15.85	12.88	3.7
3	4	Wii Sports Resort	Wii	2009.0	Sports	Nintendo	15.75	11.01	3.2
4	5	Pokemon Red/Pokemon Blue	GB	1996.0	Role-Playing	Nintendo	11.27	8.89	10.2

根据表格，可以得出：最受欢迎的游戏是： `Wii Sports` ；最受欢迎的类型是： `Sports` ；最后欢迎的发行平台是： `Wii` ；最受欢迎的发行人是： `Nintendo` 。

可以看到，这款游戏自2006年发布以来一直都很受欢迎。

另外，在全球受欢迎程度前五的发行人都是 `Nintendo` 。

In [6]:
```
def popular_rank(data, sort_by='NA_Sales'):
    print('Sort by :', sort_by)
    new_data = data.sort_values(by=sort_by, axis=0, )
    return new_data[::-1]
```

In [7]:
```
# Sort by NA_Sales/EU_Sales/JP_Sales/Other_Sales
sorted_data = popular_rank(new_data, sort_by='NA_Sales')
sorted_data.head()
```

```
Sort by : NA_Sales
```

Out[7]:

	Rank	Name	Platform	Year	Genre	Publisher	NA_Sales	EU_Sales	JP_Sales	Oth
0	1	Wii Sports	Wii	2006.0	Sports	Nintendo	41.49	29.02	3.77	
1	2	Super Mario Bros.	NES	1985.0	Platform	Nintendo	29.08	3.58	6.81	
9	10	Duck Hunt	NES	1984.0	Shooter	Nintendo	26.93	0.63	0.28	
5	6	Tetris	GB	1989.0	Puzzle	Nintendo	23.20	2.26	4.22	
2	3	Mario Kart Wii	Wii	2008.0	Racing	Nintendo	15.85	12.88	3.79	

这里展示了北美的销售情况，可以看到北美最受欢迎的游戏与全球是一致的。前五的排行略有差别，但是发行人还是 `Nintendo` 。任天堂不愧是游戏界的巨头。

预测每年电子游戏销售额

- 利用Logistic预测
- 利用RandomForest预测

将标称属性转换成数值型数据

In [8]:
```
from sklearn.preprocessing import LabelEncoder

nominal_columns = ['Name', 'Platform', 'Genre', 'Publisher']
numerical_colums = ['Year', 'Global_Sales', 'NA_Sales','EU_Sales','
JP_Sales', 'Other_Sales']

encoded_data = pd.DataFrame()
encoder = LabelEncoder()

# encode nominal colums to int
for col in nominal_columns:
    encoded_data[col] = encoder.fit_transform(new_data[col])

for col in numerical_colums:
    encoded_data[col] = new_data[col].values
```

In [9]:
```
encoded_data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 16598 entries, 0 to 16597
Data columns (total 10 columns):
 #   Column         Non-Null Count  Dtype  
---  ------         --------------  -----  
 0   Name           16598 non-null  int64  
 1   Platform       16598 non-null  int64  
 2   Genre          16598 non-null  int64  
 3   Publisher      16598 non-null  int64  
 4   Year           16598 non-null  float64
 5   Global_Sales   16598 non-null  float64
 6   NA_Sales       16598 non-null  float64
 7   EU_Sales       16598 non-null  float64
 8   JP_Sales       16598 non-null  float64
 9   Other_Sales    16598 non-null  float64
dtypes: float64(6), int64(4)
memory usage: 1.3 MB
```

In [10]:
```
encoded_data.head()
```

Out[10]:

	Name	Platform	Genre	Publisher	Year	Global_Sales	NA_Sales	EU_Sales	JP_Sales
0	11007	26	10	359	2006.0	82.74	41.49	29.02	3.77
1	9327	11	4	359	1985.0	40.24	29.08	3.58	6.81
2	5573	26	6	359	2008.0	35.82	15.85	12.88	3.79
3	11009	26	10	359	2009.0	33.00	15.75	11.01	3.28
4	7346	5	7	359	1996.0	31.37	11.27	8.89	10.22

这里指演示预测全球电子游戏销售额，将其他地区的销售额（i.e., `NA_Sales` , `EU_Sales` , `JP_Sales` , `Other_Sales` ）最为预测目标的话，也可以预测相应地区的销售额

数据集划分，按照 `8:2` 将整个数据集分成训练集和测试集

In [11]:
```python
from sklearn.model_selection import train_test_split

train, test = train_test_split(encoded_data, test_size=0.2, random_state=2020)

def data_label_split(data, type_sales='Global_Sales'):
    x = data.drop(type_sales, axis=1)
    y = data[type_sales]
    return x, y

x_train, y_train = data_label_split(train)
x_test, y_test = data_label_split(test)
```

评价指标：MAE，MSE，RMSE以及MAPE

In [12]:
```python
def mae_value(y_true, y_pred):
    n = len(y_true)
    mae = sum(np.abs(y_true - y_pred))/n
    return mae

def mse_value(y_true, y_pred):
    n = len(y_true)
    mse = sum(np.square(y_true - y_pred))/n
    return mse

def rmse_value(y_true, y_pred):
    n = len(y_true)
    mse = sum(np.square(y_true - y_pred))/n
    return mse ** 0.5

def mape_value(y_true, y_pred):
    n = len(y_true)
    mape = sum(np.abs((y_true - y_pred)/y_true))/n*100
    return mape
```

Logistic预测与评估

In [13]:
```python
from sklearn.linear_model import LinearRegression
log = LinearRegression()
log.fit(x_train , y_train)
y_pred = log.predict(x_test)

# evaluation
print('MAE: ', mae_value(y_test, y_pred))
print('MSE: ', mse_value(y_test, y_pred))
print('RMSE: ', rmse_value(y_test, y_pred))
print('MAPE: ', mape_value(y_test, y_pred))
```

```
MAE:  0.0028500275316741667
MSE:  2.6467856619900694e-05
RMSE:  0.005144692082127043
MAPE:  2.751819338017059
```

RandomForest预测与评估

In [14]:
```python
from sklearn.ensemble import RandomForestRegressor
rf_model = RandomForestRegressor(n_estimators=200,min_samples_split
=20,random_state=43)
rf_model.fit(x_train,y_train)
y_pred = rf_model.predict(x_test)

# evaluation
print('MAE: ', mae_value(y_test, y_pred))
print('MSE: ', mse_value(y_test, y_pred))
print('RMSE: ', rmse_value(y_test, y_pred))
print('MAPE: ', mape_value(y_test, y_pred))
```

```
MAE:  0.03397944891204797
MSE:  0.05350130785859775
RMSE:  0.2313034972900275
MAPE:  5.321491973678423
```

可视化应用

- 每年的销售额
- 各个平台销售的游戏类型探索
- 词云

销售额可视化

分析从1980年到2020年，各个地区和全球的销售额情况

In [15]:
```
# line chart for sales
def line_chart(data):

    x = data.index.values

    plt.figure(figsize=(20,10))
    plt.plot(x, data['Global_Sales'], label='Global', c='red')
    plt.plot(x, data['NA_Sales'], label='North America', c='peru')
    plt.plot(x, data['EU_Sales'], label='Europe', c='purple')
    plt.plot(x, data['JP_Sales'], label='Japan', c='blue')
    plt.plot(x, data['Other_Sales'], label='rest of the world', c='
yellow')

    plt.title('Annual sales per region', fontsize=20)
    plt.xlabel('Year', fontsize=20)
    plt.ylabel('Sales (in millions)', fontsize=20)
    plt.legend(loc='best', fontsize=20)
    plt.show()
```

In [16]:
```
line_chart(new_data.groupby(['Year']).sum())
```

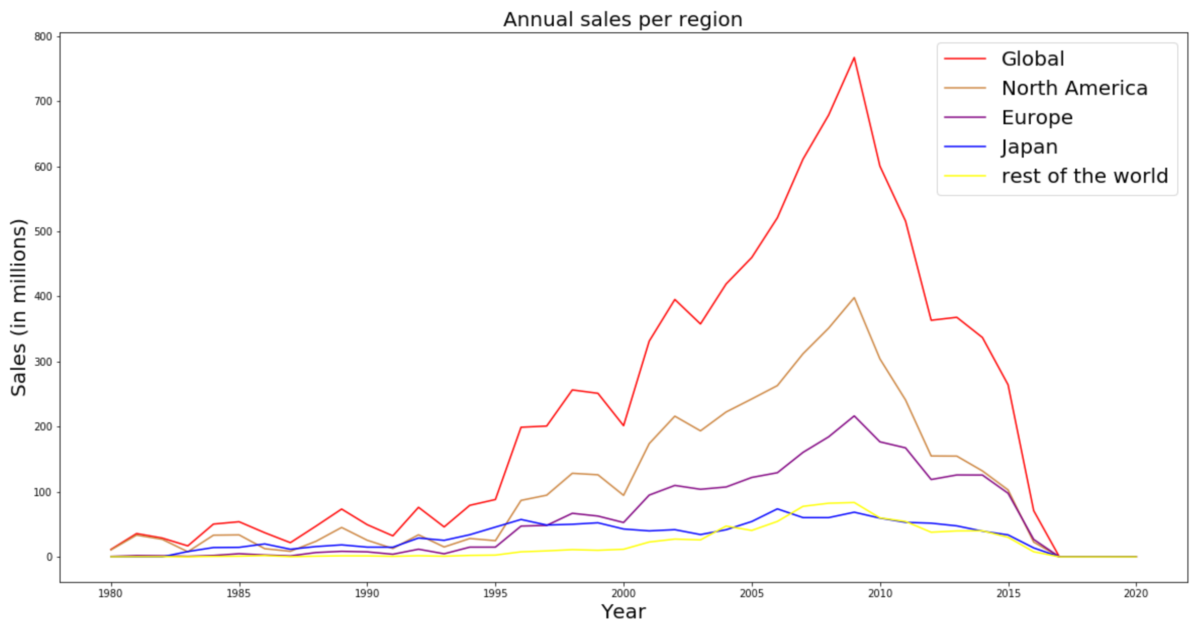

从1980年到2008年，每一年的游戏销量都在不断地增加，08年之后又开始急剧下降。

平台和游戏类型

探索 `Platform` 和 `Genre` 之间的关系

In [17]:
```
import seaborn as sns

# get data of Platform and Genre
platGenre = pd.crosstab(new_data.Platform, new_data.Genre)

# total number of Genre
platGenre['Total'] = platGenre.sum(axis=1)
popPlatform = platGenre[platGenre['Total'] > 1000].sort_values(by='
Total', ascending = False)

neededdata = popPlatform.loc[:,:'Strategy']
maxi = neededdata.values.max()
mini = neededdata.values.min()
popPlatformfinal = popPlatform.append(pd.DataFrame(popPlatform.sum(
), columns=['total']).T, ignore_index=False)

sns.set(font_scale=1.2)
plt.figure(figsize=(22,10))
sns.heatmap(popPlatformfinal, vmin = mini, vmax = maxi, annot=True,
fmt="d")
plt.xticks(rotation = 60)
plt.ylabel('Platform')
plt.title('Platform VS. Genre')
plt.show()
```

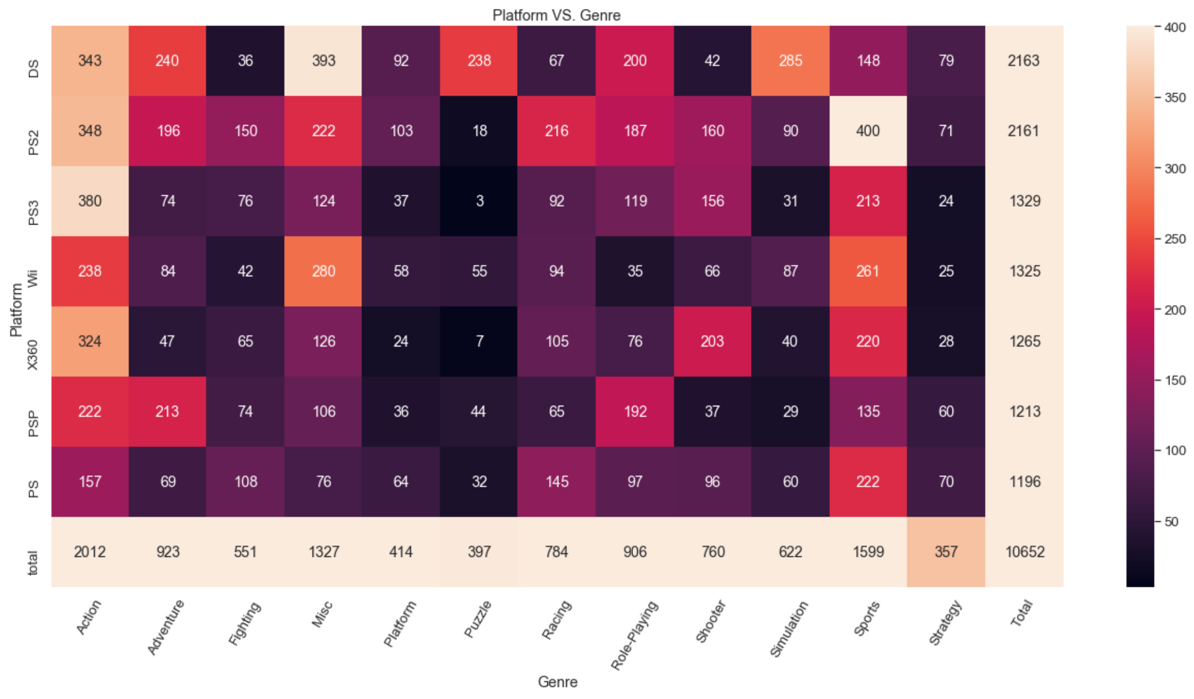

可以看到在DS和PS2平台上拥有最多的游戏。

另外，对拥有1000多个游戏的平台上，可以进一步看到不同游戏类型的详细信息。

`Action` ， `Adventure` 和 `Fighting` 在各大平台上的数量是最多的几种类型。

然后，再通过分组获得每个区域中每种游戏的销售情况。

In [18]:
```
# group by genre
GenreGroup = new_data.groupby(['Genre']).sum().loc[:, 'NA_Sales':'G
lobal_Sales']

# percentage of each region
GenreGroup['NA_Sales%'] = GenreGroup['NA_Sales']/GenreGroup['Global
_Sales']
GenreGroup['EU_Sales%'] = GenreGroup['EU_Sales']/GenreGroup['Global
_Sales']
GenreGroup['JP_Sales%'] = GenreGroup['JP_Sales']/GenreGroup['Global
_Sales']
GenreGroup['Other_Sales%'] = GenreGroup['Other_Sales']/GenreGroup['
Global_Sales']

plt.figure(figsize=(16, 20))
sns.set(font_scale=1.2)
sns.heatmap(GenreGroup.loc[:,'NA_Sales%':'Other_Sales%'], vmax =1,
vmin=0, annot=True, fmt = '.2%')
plt.title("Comparation of each region in each Genre(%)")
plt.show()
```

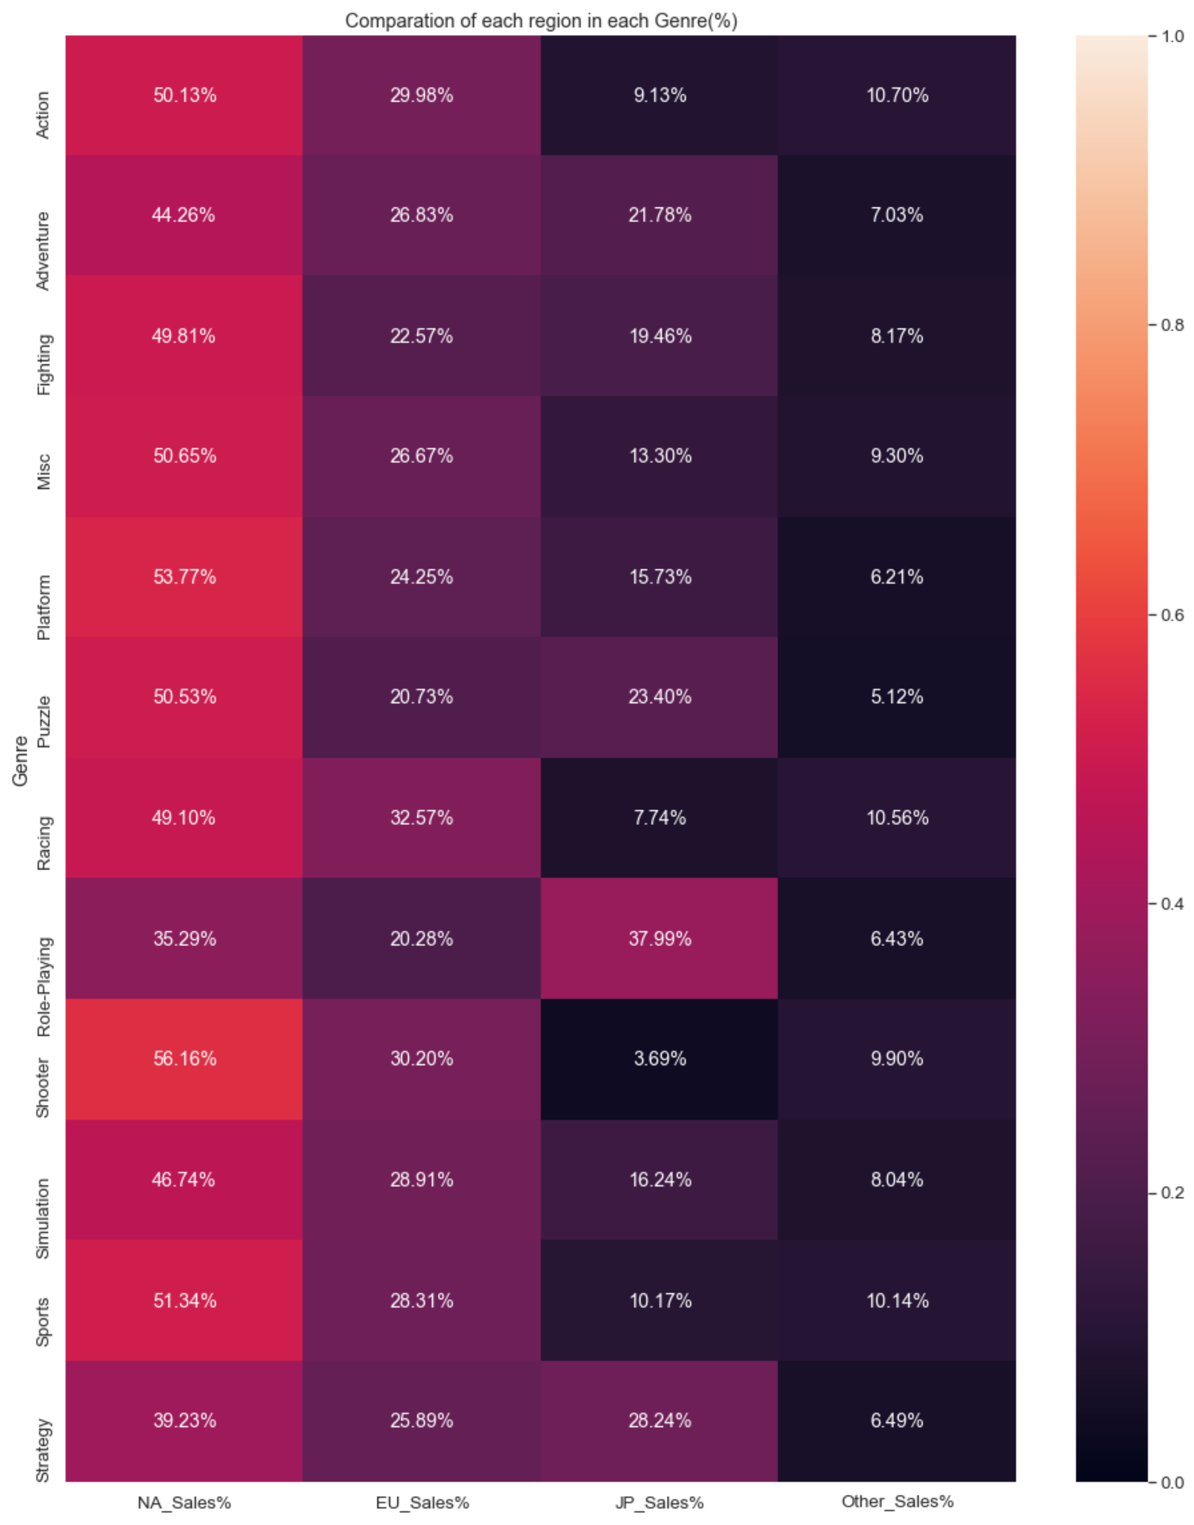

Genre	NA_Sales%	EU_Sales%	JP_Sales%	Other_Sales%
Action	50.13%	29.98%	9.13%	10.70%
Adventure	44.26%	26.83%	21.78%	7.03%
Fighting	49.81%	22.57%	19.46%	8.17%
Misc	50.65%	26.67%	13.30%	9.30%
Platform	53.77%	24.25%	15.73%	6.21%
Puzzle	50.53%	20.73%	23.40%	5.12%
Racing	49.10%	32.57%	7.74%	10.56%
Role-Playing	35.29%	20.28%	37.99%	6.43%
Shooter	56.16%	30.20%	3.69%	9.90%
Simulation	46.74%	28.91%	16.24%	8.04%
Sports	51.34%	28.31%	10.17%	10.14%
Strategy	39.23%	25.89%	28.24%	6.49%

词云

利用wordcloud工具来探索不同类型游戏中的通过以哪些关键字来命名

```
In [19]: from wordcloud import WordCloud, STOPWORDS, ImageColorGenerator

         def Genre_wordcloud(name='Action'):
             cloud = WordCloud(background_color="white", max_words=100,
                                stopwords=set(STOPWORDS), max_font_size=60, rand
         om_state=2020)
             cloud.generate(new_data.Name[new_data.Genre == name].to_string(
         ))

             plt.figure(figsize=(20,10))
             plt.imshow(cloud)
             plt.axis("off")
             plt.show()
```

首先，查看各大平台出品中最受欢迎的游戏类型 `Action` 中的命名关键字。

```
In [20]: Genre_wordcloud('Action')
```

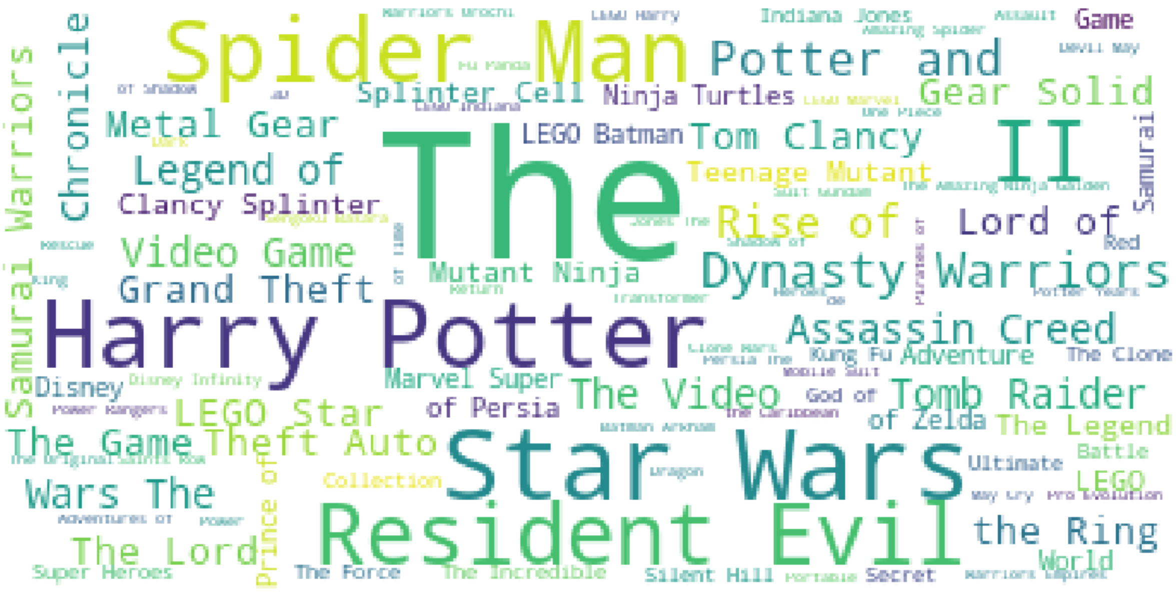

从词云中可以看出 `Action` 类游戏中，最多的是游戏名为： `The` ， `Spider Man` ， `Harry Potter` 和 `Star Wars` 。

然后，再查看下 `Adventure` 类中的命名规则

In [21]:
```
Genre_wordcloud('Adventure')
```

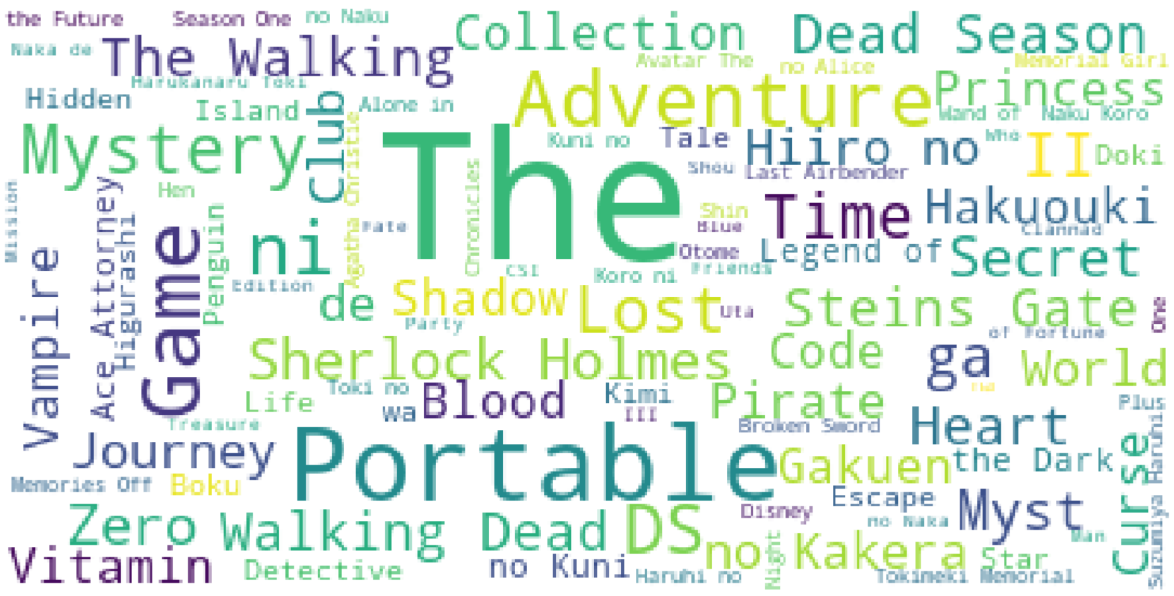

从词云中可以看出 Adventure 类游戏中，最多的是游戏名为： The ， Adventure ， Mystery 和 Portable 。

In [22]:
```
m, s = divmod(time.time()-timekeeping, 60)
h, m = divmod(m, 60)
print ('run time: %02d:%02d:%02d' % (h, m, s))
```

```
run time: 00:00:13
```